Journal of the Korean Society of Marine Environment & Safety
Research Paper
Vol. 31, No. 2, pp. 241-249, April 30, 2025, ISSN 1229-3431(Print) / ISSN 2287-3341(Online) https://doi.org/10.7837/kosomes.2025.31.2.241

# 합성 LSTM 모델을 활용한 선박 항적 예측

이희진*†
* 한국해양수산연수원 교수

# Ship Trajectory Prediction Using a Hybrid LSTM Model

Heejin, Lee*†
* Professor, Korea Institute of Maritime and Fishery Technology, Busan, Korea

**요 약 :** 정확한 선박 항적 예측은 선박의 충돌 회피 전략 수립과 자율운항 선박의 안전 운항에 중요한 요소이다. MMG(Maneuvering Modeling Group) 모델이나 CFD(Computational Fluid Dynamics)를 활용하여 선박 항적을 계산할 수 있지만, 계산을 위한 선박의 정확한 계수등을 확보하는 것은 현실적으로 어렵다. 이에 대한 대안으로, LSTM(Long Short-Term Memory)과 같은 인공지능을 활용한 항적 예측 연구가 진행되고 있다. 그러나 LSTM 단독으로는 선박의 복잡한 비선형적 움직임을 완벽히 예측하는데 한계가 있다. 예측 정확도를 향상시키기 위해 본 연구에서는 STL-CNN-LSTM 하이브리드 모델을 제안한다. 이 모델은 STL (Seasonal and Trend decomposition using Loess)을 이용한 데이터를 분해하고, CNN(Convolutional Neural Network)을 활용한 데이터의 특징 추출, 그리고 LSTM을 통한 학습이 이뤄진다. 이 연구는 CNN-LSTM에 비해 얼마나 더 높은 항적 예측도를 보여주는지 비교 분석한다. 분석 결과, STL-CNN-LSTM 모델은 CNN-LSTM보다 우수한 예측 성능을 보이며, 예측 오차는 1~5미터 범위 내에 있는 것으로 나타났다. 이러한 연구 결과는 정밀한 충돌 회피 전략 개발에 기여할 수 있으며, 향후 연구에서는 실무 적용을 위한 충돌회피 모델의 설계 고도화 연구에 적용될 것이다.

**핵심용어 :** 충돌회피, STL-CNN-LSTM, 선박충돌, 항적예측, 인공지능

**Abstract :** *Accurate trajectory prediction of ships is essential for developing collision avoidance strategies and ensuring safe navigation of autonomous ships. Although ship trajectories can be calculated using the Maneuvering Modeling Group (MMG) or Computational Fluid Dynamics (CFD) models, obtaining precise coefficients for these calculations is often impractical. Alternatively, artificial intelligence-based approaches, such as Long Short-Term Memory (LSTM), have been explored for trajectory prediction. However, LSTM alone has limitations in accurately predicting the complex nonlinear movements of ships. To enhance predictive accuracy, this study proposes an STL-CNN-LSTM hybrid model. This model uses Seasonal and Trend decomposition using Loess (STL) for data decomposition, a Convolutional Neural Network (CNN) for feature extraction, and LSTM for sequential learning. This study compares the predictive performance of STL-CNN-LSTM with that of CNN-LSTM to assess its effectiveness. The results demonstrate that the STL-CNN-LSTM model outperforms CNN-LSTM model, limiting prediction errors within the range of 1–5 m. These findings contribute to the development of precise collision avoidance strategies, and future research should focus on advancing collision avoidance models for real-world implementation.*

**Key Words :** *Collision avoidance, STL-CNN-LSTM, Ship collision, Trajectory prediction, AI*

## 1. 서 론

선박의 충돌회피는 안전운항에 가장 중요한 요소중 하나이다(Lee and Park, 2024). 선박의 충돌회피를 위해서 타선 또는 본 선박의 변침 동작이 예측 가능하다면, 충돌회피 계획을 수립하는데 용이할 것이다. 그런데 선박 항적 예측은 어려운 부분이 있는데 이는 다음과 같다.

선박의 종류는 다양하고, 동일한 선종의 선박이더라도 세밀한 선형의 차이, 엔진 마력의 차이 등으로 각 선박들의 조종성능에 차이가 있다. 그럼에도 불구하고 선박 항적 계산은 MMG(Maneuvering Modeling Group), CFD(Computational Fluid Dynamics)로 가능 하지만, 모든 선박의 항적을 계산을 하기에 어려움이 있다. 왜냐하면 특정 선박의 항적을 계산하기 위해서는 구체적인 선박의 제원과, 항적 계산에 필요한 여러 계수들이 필요한데, 이를 확보하여 계산하기가 현실적으로 쉽지 않기 때문이다.

† heejin1911@seaman.or.kr, 051-620-5806

그렇다면 간단한 방법은, 실제 선박의 항적 데이터를 인공지능 모델로 학습하여 예측하는 방법이다. 인공지능의 기술개발로 다양한 분야에 인공지능 모델이 적용되고 있다(Lee and Park, 2024). 그 중 선박의 항적은 시계열 데이터로써, 인공지능 모델을 통해서 선박의 항적이 예측 가능하다. 시계열 데이터 예측에 강점을 보이는 모델 중 대표적인 모델은 LSTM(Long Short-Term Memory)이다(Lee and Park, 2024). LSTM은 인간의 뇌를 모사하여 과거의 것을 얼마나 잃어버리고, 얼마나 기억할 것인지를 통해 값을 예측한다(Gers et al., 2000). 하지만 LSTM 또한 복잡한 선박의 항적 예측에 한계가 있다(Lee and Park, 2024). 선박의 항적은 선형적 특성과 비선형적 특성을 동시에 보이기 때문이다. 선박이 회두 동작을 할 때, 크게 보면 곡선을 그리며 움직이나, 그 세부적 움직임이 비선형적으로 움직이기 때문이다.

이러한 LSTM의 한계를 극복하기 위해 합성 LSTM 모델이 출현했다(Karijadi and Chou, 2019; Yang et al., 2021; Shohan et al., 2022; Zha et al., 2022). 하지만 LSTM 모델만으로는 선박의 항적을 예측하기 힘들다(Lee and Park, 2024). 그래서 다른 인공지능 모델 또는 알고리즘과 결합한 합성 LSTM 모델은 기존의 LSTM 모델이 가지고 있던 한계점을 극복했다(Hajirahimi and Khashei, 2019; He et al., 2022; Li et al., 2020; Lee and Park, 2024). 저자는 이미 이와 관련된 연구를 진행한 바 있는데 CNN(Convolutional Neural Network)과 LSTM을 결합한 CNN-LSTM 모델을 통한 선박 항적 예측 연구를 진행하였다(Lee and Park, 2024). CNN-LSTM 모델은 기존의 LSTM에 비해 높은 정확도를 보여 주었다. 이 외에도 다양한 합성 LSTM 모델을 활용한 항적 예측 연구가 다양하게 진행 되었다(Abebe et al., 2022; Zhang et al., 2022). 다양한 합성 모델의 출현으로 선박의 항적 예측 능력은 향상되었다. 다양한 합성 모델의 출현으로 선박의 항적 예측 능력은 향상되었다. 하지만 존재하는 오차를 지속적으로 줄이기 위해 본 연구는 3가지 요소로 구성된 합성 모델을 활용한다

여러 합성 모델 중 이 연구는 STL-CNN-LSTM을 통한 항적 예측 연구를 진행하고자 한다. STL-CNN-LSTM에서 시계열 데이터의 추세와 계절성을 분해하는 STL(Seasonal and Trend decomposition using Loess) 기법과, 공간적 특징 추출에 강점이 있는 CNN(Convolutional Neural Network)을 LSTM과 결합한 합성 모델이다. 합성 LSTM 모델은 데이터의 복잡성을 효과적으로 처리하여 예측 성능을 향상 시킬 수 있는 잠재력을 지니고 있다(Zhu et al., 2022).

본 연구 결과를 기존의 합성 모델들과 비교해 보려 하였지만, 다른 모델들과의 비교에 어려움이 있었다. 첫째, 기존의 연구들은 AIS 데이터에 기반한 선박 항적 예측 연구이다. 그래서 선박의 선회 각도가 그리 크지 않다. 둘째, 기존 연구들의 선회 각도가 각각 다르기 때문에, 모델의 우수성을 비교하기 어려움이 있다. 그래서 본 연구는 기존의 CNN-LSTM과 비교를 통해 본 연구 모델의 우수성을 검토해 보고자 한다.

## 2. 연구 방법

이 장에서는 본 연구가 어떻게 진행 될 것인가에 대해 기술 할 것이다. 먼저 항적 계산을 위해 모델 선박을 지정하고 항적을 계산을 한다. 그리고 계산된 항적을 합성 LSTM 모델을 활용하여 어떻게 예측하는지에 대한 방법이 기술될 것이다.

### 2.1 항적계산

본 연구에서 선박의 항적 계산은 KRISO에서 개발한 프로그램을 활용하여 진행 되었다. 선박 항적 계산은 식(1)과 같고 계산에 활용되는 모델 선박의 상세 사항은 Table 1과 같으며 선박의 항적 계산은 0.1초 간격으로 이루어진다.

$$\begin{cases} m(\dot{u} - vr - x_G r^2 + z_G pr) = X_H + X_R + X_P \\ m(\dot{v} + ur + x_G \dot{r} - z_G \dot{p}) = Y_H + Y_R + Y_P \\ I_{zz}\dot{r} + mx_G(\dot{v} + ur) = N_H + N_R \end{cases} \quad (1)$$

Table 1. Ship's particular

| Ship parameter | Bulk carrier | Container carrier |
|---|---|---|
| Length (m) | 274 | 300 |
| Breadth (m) | 32.30 | 40 |
| Draft (m) | 12.70 | - |
| Block coefficient ($C_b$) | 0.65 | - |
| Speed (Knots) | 12.0/14.0 | 14.0/16.0 |
| Rudder angle | 35° | 35° |

식(1)에서, $m$은 선박의 질량을, $u$, $v$, $r$은 $x$, $y$, $z$축의 속력을 $p$는 $x$축을 따라 회전하는 각속도를, $x_G$, $z_G$는 $x$, $z$축에 대한 선박의 중심을, $\dot{u}, \dot{v}, \dot{r}$는 $u$, $v$, $r$에 대한 가속도, $\dot{p}$은 각가속도를, $I_{zz}$는 z축에 대한 회전 관성 모멘트를 H, R, 그리고 P는 hull, rudder, propeller를 의미한다. 본 연구에서는 외력(조류, 파도 등)의 영향을 제외한 환경에서 bulk선과 container선을 대상으로 항적을 계산한다. 그리고 타각은 35도로 사용할 경우만을 고려해 항적을 계산한다. 선박의 속력은 일반적으로 모델 선박들이 항해하는 속력들을 각각 두 경우로 설정

한다. 그리고 선박의 항적은 시뮬레이션이 시작되고 300초까지 계산하도록 설정했다. 이는 일반적인 충돌회피 변침(10~50도)보다 복잡한 대각도 선회 패턴을 포함하여 인공지능 모델의 비선형 항적 예측 성능을 충분히 검증할 수 있는 시간 범위로 판단 되었기 때문이다. 이 시간 범위는 선박의 회전 모멘텀이 충분히 발생하면서도 실제 해상에서 발생 가능한 현실적인 선회 범위를 벗어나지 않는 균형점으로 판단되어 설정되었다.

### 2.2 선박의 항적 예측

STL-CNN-LSTM 모델은 시계열 데이터의 복잡성을 효과적으로 처리하고 예측 성능을 극대화하기 위해 설계된 합성 딥러닝 모델이다. 이 모델은 세가지 주요 구성 요소인 STL, CNN, LSTM을 결합하여 각각의 장점을 통합한다. Fig. 1은 해당 모델의 구조도를 나타낸다.

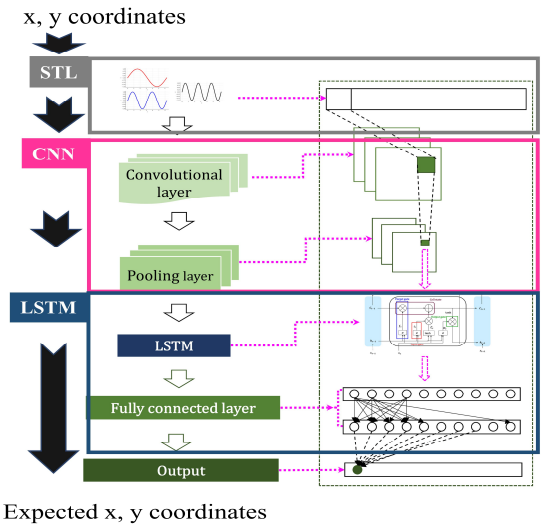



Fig. 1. Structure of hybrid LSTM model.

Fig. 1에서 보듯 합성 LSTM 모델은 3가지 모델이 결합 되어 구성되고, 선박 조종 방정식에 의해 계산된 각각의 *x, y* 좌표 데이터를 전처리 과정 없이 입력하여 예측한 *x, y* 좌표를 출력하도록 구성한다. 단계별 과정에 대해 간략히 설명해 보자면, STL에서는 전체적인 선박의 곡선 움직임에 대해 학습이 용이하도록 데이터의 3가지 특성을 추출한다. CNN에서는 선박의 곡선 운동에서 국소적인 이동 패턴에 대해 학습하게 된다. 마지막으로 LSTM은 데이터의 특성에 대한 결과들을 시간에 변화에 따라 학습하여 최종 출력하게 된다. 보다 자세한 설명은 아래와 같다.

Fig. 1에서 STL은 시계열 데이터를 추세(Trend), 계절성(Seasonality), 잔차(Residual)로 분해하여 데이터의 구조적 복잡성을 감소시킨다. 본 연구에서 *x, y* 좌표들은 선박의 좌표 이동경향의 추세가 될 것이고, 좌표들의 주기적인 변화는 계절성에 해당하고, 좌표값들의 변동은 잔차에 해당한다. 즉 선박의 일정한 곡선을 그리고 이동하는 경우 STL은 이 곡선의 일반적인 형태를 추출하여 학습에 반영한다. 만약 데이터 일부가 변칙적으로 움직이면 이를 제거하고 안정적인 이동 패턴을 추출한다. 본 연구에서는 50개의 좌표에 대해 추세, 계절성, 잔차를 구별해낸다. 이를 통해 각 성분의 특성을 독립적으로 분석할 수 있으며, 모델 학습 과정에서 불필요한 노이즈를 제거함으로써 예측 정확도를 향상시킨다(Zhu et al., 2022). 이를 수식으로 나타내면 식(2)와 같다.

$$\begin{cases} Y_t = T_t + S_t + R_t \\ T_t = Loess(Y_t - S_t) \\ S_t = \dfrac{1}{k}\sum_{i=1}^{k}(Y_{t-iP} + Y_t + Y_{t+iP}) \\ R_t = Y_t - T_t - S_t \end{cases} \tag{2}$$

식(2)에서 $Y_t$는 원데이터, $T_t$는 추세, $S_t$는 계절성, $R_t$는 잔차를, $k$ 값은 인접한 주기수를, P는 데이터의 주기를 의미한다. 시계열 데이터인 $Y_t$는 추세, 계절성, 잔차로 분해가 되고, 이 3가지 성분들은 식(2)와 같이 계산이 된다.

그래서 Loess 함수를 사용하여 데이터의 추세를 파악하기 용이하게 만들고, 50개의 좌표에서 반복되는 패턴을 찾고 분석한다. 이를 통해 데이터의 추세 뿐 아니라 계절성과 잔차를 구별 해낸다.

STL 분해 후, 좌표의 추세 성분이 CNN layer로 전달되어 시간적 패턴과 특징이 추출된다. Fig. 1과 같이, CNN은 Convolutional layer에서 시계열 데이터에 대해 합성곱 연산을 수행하며, 본 연구에서는 커널 크기(kernel size) 3과 64개의 필터(filter)를 사용하여 3개의 연속 좌표를 64가지 방식으로 특성을 파악한다. 이어지는 Pooling layer에서는 특징 맵에서 가장 중요한 정보를 추출하여 다운샘플링을 수행한다. 이 과정은 계산 복잡성을 낮추고, 과적합을 방지하며, 시간 데이터의 미세한 이동에도 모델이 견고하게 작동하도록 돕는다.

CNN은 주로 이미지 데이터에서 사용되지만, 시계열 데이터에서도 특정 패턴 및 국소적 정보를 효과적으로 학습할 수 있다(Li et al., 2020).

CNN의 연산과정을 수식으로 나타내면 식(3)과 같다.

$$\begin{cases} h(i,j) = \sum_c \sum_m \sum_n x_c(i+m, j+n) \cdot w_c(m,n) + b \\ h'(i,j) = ReLU(h(i,j)) = \max(0, h(i,j)) \end{cases} \tag{3}$$

식(3)에서 $h(i,j)$는 좌표 데이터의 위치를 나타내고, $x_c=(i+m,j+n)$은 입력 데이터의 c번째 채널에서의 값을, $w_c=(m,n)$은 필터의 c번째 채널에서의 값을, b는 바이어스 값을 의미한다. 식(3)의 첫 번째 식은 입력 데이터의 특징을 생성하고, 생성된 값에 비선형성을 추가하여 ReLU 함수를 이용해 모델의 학습 능력을 향상 시킨다. ReLU 활성화 함수는 선박의 $x$, $y$ 좌표 데이터가 CNN에 입력될 때 중요한 역할을 한다. 먼저, CNN의 합성곱 연산을 통해 선박의 이동 패턴을 분석하는데, 이 $(h(i,j)=\sum_c\sum_m\sum_n x_c(i+m,j+n)\cdot w_c(m,n)+b)$ 과정에서 일부 값들은 음수로 변할 수 있다. ReLU 함수는 이 음수 값을 모두 0으로 바꿔주어, 선박이 실제로 이동하는 중요한 부분만 남기고, 불필요한 정보는 제거하도록 돕는다. 예를 들어, 선박의 좌표 이동 변화가 적은 부분은 0이 되어 모델이 학습할 필요가 없는 데이터로 인식하게 된다.

LSTM은 CNN에서 추출된 특징을 입력으로 받아 시계열 데이터의 시간적 의존성을 학습한다. LSTM은 RNN(Recurrent Neural Network)의 개선된 구조로, 장기 의존성 문제를 해결하고 시계열 데이터의 미래값을 효과적으로 예측할 수 있다 (Gers et al., 2000).

CNN을 거친 데이터는 LSTM에서 시간에 따른 선박의 이동한 좌표에 대해 학습하게 된다. 즉 과거 몇 초간 선박의 좌표가 어떻게 움직였는지 학습한 후 다음 좌표에 대한 위치에 대해 예측한다. 예를 들어 10초간 회두 속도가 증가한다면, LSTM은 이를 기억하고 다음 좌표가 더 빠르게 이동할 가능성이 있다고 예측하게 된다. 반대로 회두 속도가 일정하게 유지되고 있다면, 곡선을 유지하는 방향으로 예측하게 된다.

$$\begin{cases} f_t=\sigma(W_f[x_t,h_{t-1}]+b_f) \\ i_t=\sigma(W_i[x_t,h_{t-1}]+b_i) \\ \tilde{C}_t=\tanh(W_c[x_t,h_{t-1}]+b_c) \\ C_t=f_t\cdot C_{t-1}+i_t\cdot\tilde{C}_t \\ O_t=\sigma(W_o[x_t,h_{t-1}]+b_o) \\ h_t=O_t\cdot\tanh(C_t) \end{cases} \quad (4)$$

식(4)에서 $W_f, W_i, W_o, W_c$는 각 망각 게이트의 입력, 출력 게이트, 그리고 블록 입력의 가중치를 나타내고, $b_f, b_i, b_c, b_o$는 각각에 대응하는 바이어스를 나타낸다. $\sigma$는 시그모이드 활성화 함수를, tanh는 하이퍼볼릭 탄젠트 활성화 함수를 나타낸다. $C_t$는 현재 메모리 상태를, $C_{t-1}$는 이전 메모리 상태를 나타내고, $\hat{C}_t$는 새로운 기억의 후보 값, $O_t, x_t, h_t, h_{t-1}$은 현재 출력, 현재 입력, 현재 은닉 상태, 그리고 이전 은닉 상태를 나타낸다. 은닉 상태는 이전 정보를 요약하고 다음 시점으로 전달하는 값이다. 이를 나타내면 Fig. 2와 같다.

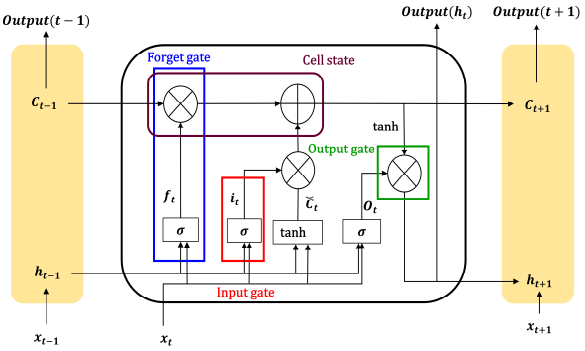



Fig. 2. Structure of LSTM.

Fig. 2은 Fig. 1의 LSTM의 학습 과정에서 시간에 따른 정보 흐름을 더욱 자세하게 나타낸다. 먼저, 입력$x_t$와 이전 은닉 상태 $h_{t-1}$를 활용하여 후보 기억 셀 값 $\hat{C}_t$가 생성되며, 입력 게이트$(i_t)$가 이를 최종 기억 셀$(C_t)$에 얼마나 반영할지 결정한다. 망각 게이트$(f_t)$는 이전 기억$(C_{t-1})$에서 잊어야 할 정보를 선택하며, 이후 $C_t$는 $C_{t-1}$와 $\hat{C}_t$를 조합하여 최종적으로 업데이트 한다. 출력 게이트$(o_t)$가 현재 기억 상태$(C_t)$에서 출력할 정보를 조절하고, 이를 바탕으로 새로운 값이$(h_t)$ 생성되어 다음 시점으로 전달된다. $h_t$은 FC layer에서 학습된 가중치와 더해져 식(5)와 같이 최종 출력을 하게 된다.

$$y=W_y\cdot h_t+b_y \quad (5)$$

여기서, y는 최종 출력값, $W_y$는 FC layer의 가중치, $h_t$는 LSTM의 결과값, $b_y$는 바이어스이다.

본 연구에서 LSTM 모델은 64개의 유닛, Dropout(0.2), Dense(32, activation='relu'), 최종 Dense(1, activation='linear')로 설정되었다. 64개의 유닛은 시계열 데이터의 복잡한 패턴을 기억하며, 시계열 데이터의 마지막 시간 스텝$(h_t)$에 대한 출력만 생성한다. 과적합 방지를 위해 LSTM 출력 뉴런 중 20%를 무작위로 비활성화하고, 데이터의 특징을 32개 유닛으로 압축하여 비선형성을 추가한다. 최종적으로 Dense(1) layer는 선박의 좌표를 단일 값으로 예측한다. 이 구조는 선박 궤적 예측의 정확성과 일반화 성능을 향상 시킨다.

모델의 학습을 위한 파라미터는 Table 2와 같이 설정하였다.

Table 2. Hyperparameter

| Parameter | Value |
|---|---|
| Batch size | 16 |
| Epoch | 100 |
| Window size | 56 |
| Learning rate | 0.001 |
| Train-Validation-Test | 80% / 10% / 10% |

배치 크기 16과 100 에포크로 안정적이고 효율적인 학습이 이루어졌으며, 윈도우 크기 56과 학습률 0.001로 설정하여 학습했다. 본 연구에서 window size는 56으로 56개의 데이터를 학습한 뒤 다음 좌표에 대해 예측하도록 설정하였다. 그리고 학습은 80% 좌표 데이터를 학습하여 10%는 검증, 10%는 테스트를 하도록 설정하였다. 훈련 데이터는 모델을 학습하기 위한 데이터이고 검증 데이터는 학습 과정의 성능을 평가하여 과적합을 방지하기 위해 사용된다. 그리고 테스트 데이터는 학습이 완료된 모델의 최종 성능을 평가하는 데이터이다. 3장에서는 테스트 데이터에 대한 결과를 분석해볼 것이다.

## 3. 결 과

프로그램에 의해 계산된 항적과 STL-CNN-LSTM의 예측 항적 비교는 bulk 선박과 container 선박의 항적 데이터를 기반으로 각각의 속력 조건에서 수행되었다. 이를 통해 모델의 예측 성능과 속력에 따른 변화 양상을 파악하고자 하였다.

### 3.1 STL-CNN-LSTM의 항적 예측 결과

이번 장에서는 선박의 항적에 대한 예측된 테스트 값에 대해 분석해 볼 것이다. Fig. 3은 이번 실험에서 선박 조종 방정식에 의해 계산된 선박의 항적 나타내며, 그림의 가로축과 세로축은 *x, y* 좌표를 나타내고 case 별로 색을 달리하여 항적을 나타내었다. 본 연구에서 선박의 항적은 300초간 계산이 되었고 속력과 선종의 차이에 따라 항적이 어떻게 달라지는지 보여준다. 선박의 항적 테스트 항적은 제시된 항적에서 마지막 300개의 좌표값 들에 대해 예측하고, 이를 나타낸 것이 Fig. 4~11이다.

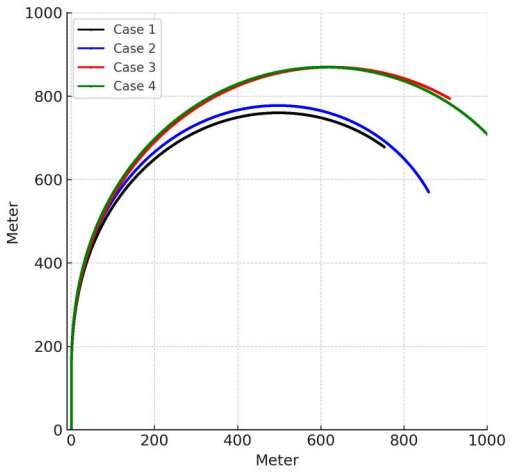



Fig. 3. Ship's trajectories.

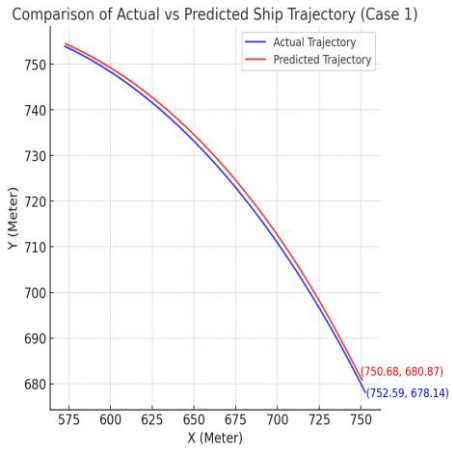



Fig. 4. Compare ship trajectories, Case 1.

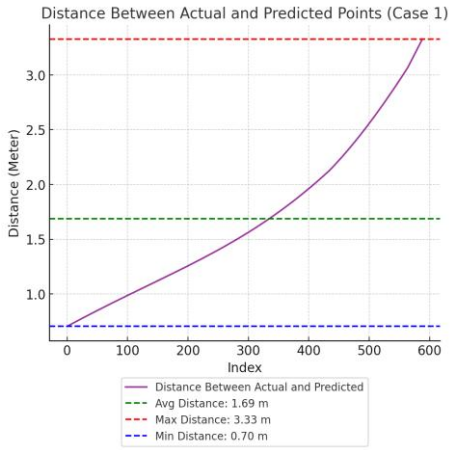



Fig. 5. Detailed result analysis, Case 1.

Figs. 4~11는 총 네 가지 경우(Case 1~4)에 대한 계산된 항적과 예측 항적의 비교와 거리 오차를 시각적으로 나타낸다. Figs. 4와 5는 Case 1로 bulk 선박이 12노트로 항해한 경우를 나타낸다. 실제 항적과 예측 항적 간의 거리 오차는 평균적으로 1.69m로 매우 낮게 나타났으며, 최소 거리 오차는 0.70m, 최대 거리 오차는 3.33m로 확인되었다. 이는 12노트의 낮은 속도에서 bulk 선박의 항적이 모델에 의해 안정적으로 예측될 수 있음을 의미한다.

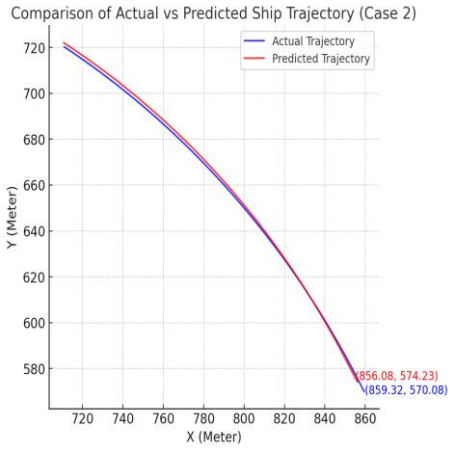



Fig. 6. Compare ship trajectories, Case 2.

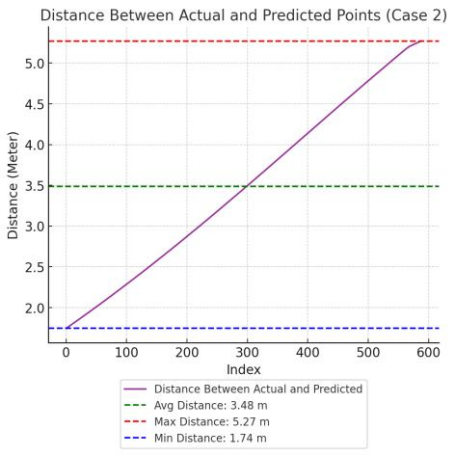



Fig. 7. Detailed result analysis, Case 2.

Figs. 6과 7은 Case 2로 bulk 선박이 14노트로 항해한 경우를 분석하였다. 이 경우 평균 거리 오차는 3.48m로, Case 1 대비 소폭 증가하였으나 여전히 높은 예측 정확도를 유지하였다. 최소 거리 오차는 1.74m, 최대 거리 오차는 5.27m로 나타냈다. 속도가 증가함에 따라 오차가 증가했지만, 항적 예측 성능은 큰 변동 없이 안정적인 경향을 보였다.

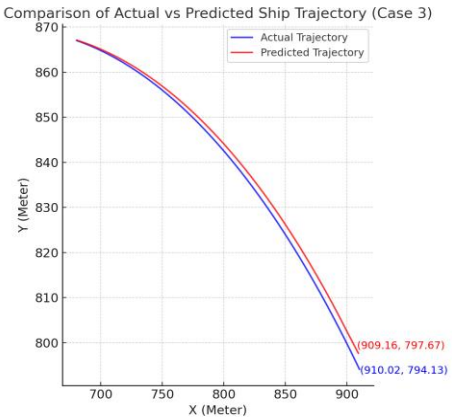



Fig. 8. Compare ship trajectories, Case 3.

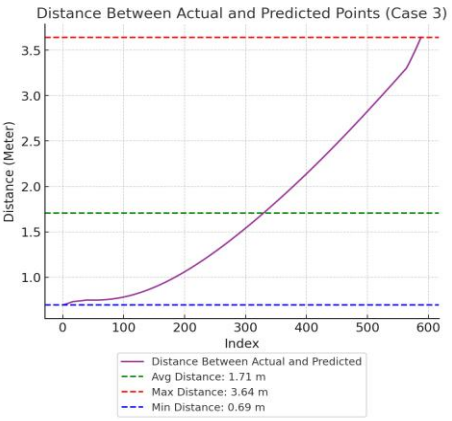



Fig. 9. Detailed result analysis, Case 3.

Figs. 8과 9는 Case 3으로 container 선박이 14노트로 운항한 경우를 분석한 결과이다. 평균 거리 오차는 1.71m이고, 최소 거리 오차는 0.63m, 최대 거리 오차는 3.64m로 확인되었다. 이는 container 선박이 14노트의 중속으로 운항할 때 예측 모델이 실제 항적을 매우 정밀하게 추적할 수 있음을 보여준다.

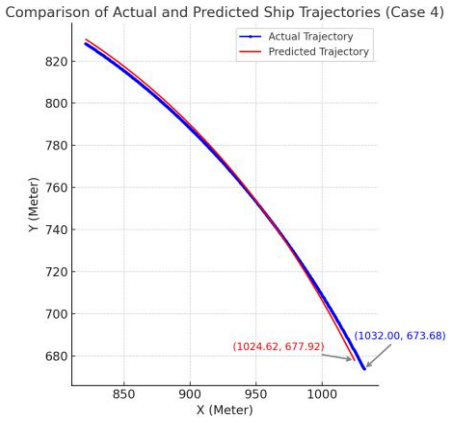



Fig. 10. Compare ship trajectories, Case 4.

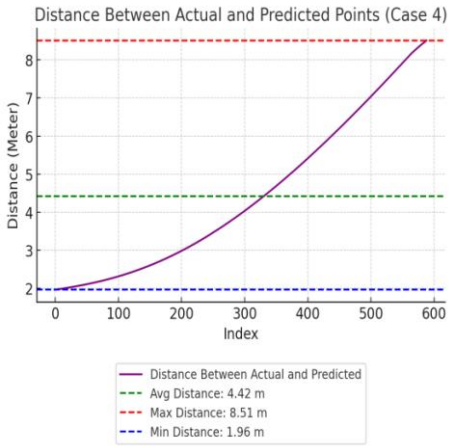



Fig. 11. Detailed result analysis, Case 4.

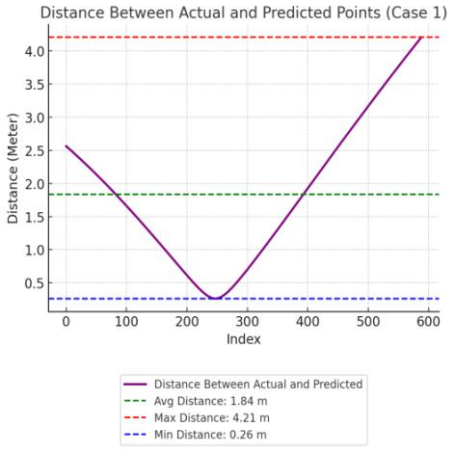



Fig. 12. Result of CNN-LSTM, Case 1.

Figs. 10과 11은 Case 4로 container 선박이 16노트로 항해한 경우를 나타낸다. 이 경우 평균 거리 오차는 4.42m로 증가하였으며, 최소 거리 오차는 1.96m, 최대 거리 오차는 8.51m로 나타났다. 이는 속력 증가로 인해 예측 값에 영향을 미친 것으로 해석된다. 특히, container 선박은 선속이 증가할 수록 보다 큰 회전 관성으로 인해 항적의 비선형적 변화가 커서 모델의 성능이 다소 저하되는 경향을 보였다.

### 3.2 합성 모델 간의 결과 비교

본 연구에서는 CNN-LSTM과 STL-CNN-LSTM 두 가지 모델을 활용하여 선박 항적 예측의 성능을 비교하였다. 이를 위해 평균 거리, 최대 거리, 최소 거리의 세 가지 지표를 사용하였으며, 네 가지 경우에 대해 각각의 결과를 분석 하였다. Table 3은 두 합성 모델의 예측 결과를 비교하기 위해 요약한 것이고, Figs. 12~15는 STL-CNN-LSTM과의 비교를 위해 CNN-LSTM의 항적 예측 결과를 나타낸다.

Table 3. Results

(unit : meter)

| Case | Model | Avg. Dis. | Max. Dis. | Min. Dis. |
|---|---|---|---|---|
| 1 | CNN-LSTM | 1.84 | 4.21 | 0.26 |
| | STL-CNN-LSTM | 1.69 | 3.33 | 0.70 |
| 2 | CNN-LSTM | 4.50 | 7.93 | 1.44 |
| | STL-CNN-LSTM | 3.48 | 5.27 | 1.74 |
| 3 | CNN-LSTM | 2.02 | 3.47 | 1.45 |
| | STL-CNN-LSTM | 1.71 | 3.64 | 0.69 |
| 4 | CNN-LSTM | 6.89 | 11.76 | 4.35 |
| | STL-CNN-LSTM | 4.42 | 8.51 | 1.96 |

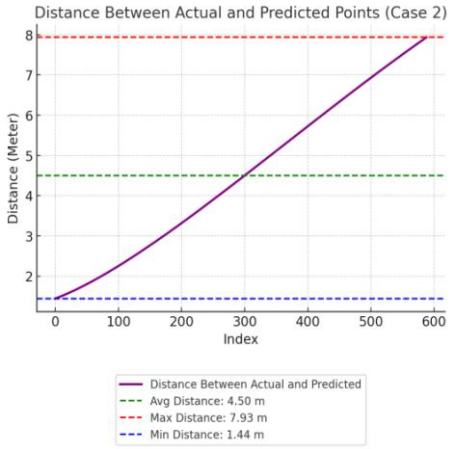



Fig. 13. Result of CNN-LSTM, Case 2.

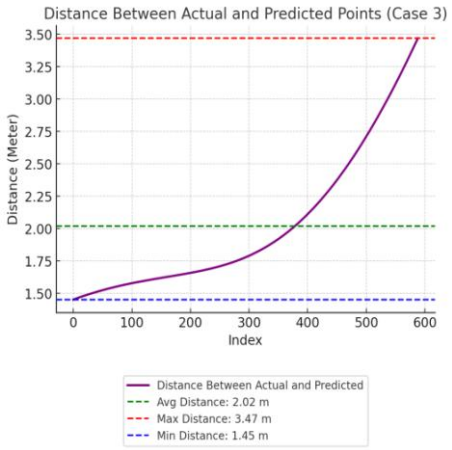



Fig. 14. Result of CNN-LSTM, Case 3.

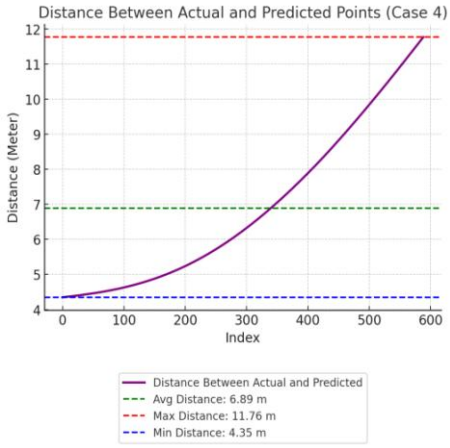



Fig. 15. Result of CNN-LSTM, Case 4.

두 합성 모델과의 비교 결과, STL-CNN-LSTM이 훨씬 더 우수한 성능을 보여주었다. 두 합성 모델간의 자세한 비교 분석은 아래와 같다.

Case 1은 bulk 선박이 12노트로 항해한 경우이다. STL-CNN-LSTM 모델의 평균 거리 오차는 1.69m로, CNN-LSTM 모델의 1.84m에 비해 약간 더 낮은 값을 보였다. 또한 STL-CNN-LSTM의 최대 거리 차이는 3.33m로 더 높은 정확도를 보여주었지만, 최소 거리는 0.70m, CNN-LSTM은 0.26m로 CNN-LSTM이 더 우수한 성능을 나타내었다. 하지만 낮은 속도에서 STL-CNN-LSTM이 전반적으로 더 안정적인 예측 성능을 보임을 확인할 수 있었다.

Case 2는 bulk 선박이 14노트로 항해한 경우를 나타낸다. STL-CNN-LSTM 모델은 평균 거리 오차가 3.48m로 CNN-LSTM의 4.50m보다 낮았으며, 최대 거리와 최소 거리 역시 STL-CNN-LSTM이 각각 5.27m와 1.74m로, CNN-LSTM의 7.93m와 1.44m보다 더 나은 성능을 보였다. 이는 속도가 증가했음에도 STL-CNN-LSTM이 CNN-LSTM에 비해 더 높은 예측 성능을 유지함을 보여준다.

Case 3은 container 선박이 14노트로 항해한 경우이다. 두 모델 모두 안정적인 성능을 보였으나, STL-CNN-LSTM은 평균 거리 오차가 1.71m로 CNN-LSTM의 2.02m보다 더 낮았다. 최대 거리와 최소 거리에서도 STL-CNN-LSTM은 각각 3.64m와 0.69m로, CNN-LSTM의 3.47m와 1.45m보다 우수한 결과를 보였다. 이는 중간 속도에서 STL-CNN-LSTM이 더욱 정밀한 예측을 수행할 수 있음을 시사한다.

Case 4는 container 선박이 16노트로 항해한 경우이다. 이 경우에서는 두 모델 모두 속도 증가로 인해 오차가 증가하는 경향을 보였으나, STL-CNN-LSTM은 평균 거리 오차가 4.42m로 CNN-LSTM의 6.89m보다 낮았다. 최대 거리와 최소 거리 역시 STL-CNN-LSTM이 각각 8.51m와 1.96m로, CNN-LSTM의 11.76m와 4.35m보다 더 나은 성능을 보였다. 이는 STL-CNN-LSTM이 높은 속도에서도 상대적으로 더 안정적인 예측 성능을 유지할 수 있음을 보여준다. 다만 container 선박의 선속이 증가함에 따라 회전 모멘텀이 커질 것이다. 이 경우 다른 경우들보다 다소 큰 오차를 보여주었다.

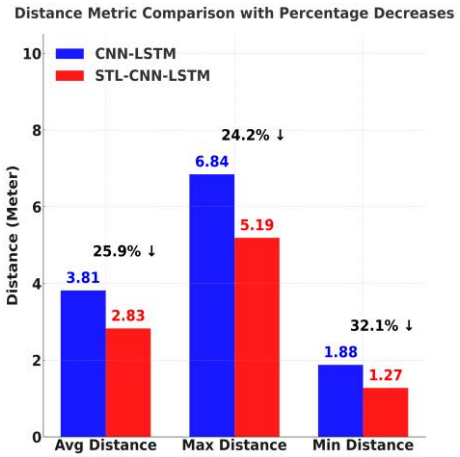



Fig. 16. Compare results from two models.

Fig. 16는 네가지 실험 결과의 평균, 최대, 최소 거리 각각의 값들의 평균 값을 비교 해보았다.

STL-CNN-LSTM 모델은 CNN-LSTM 모델에 비해 예측 정확도와 안정성 면에서 더 뛰어난 성능을 보였다. 모든 경우의 평균 거리에서 STL-CNN-LSTM은 CNN-LSTM보다 약 25.9% 감소한 2.83m를 기록하였다. 이는 STL-CNN-LSTM이 평균적으로 더 정확한 예측 결과를 제공한다는 것을 나타낸다.

최대 거리 측면에서도 STL-CNN-LSTM은 CNN-LSTM 대비 약 24.2% 감소를 보이며, 5.19m로 나타났다. 이러한 결과는 STL-CNN-LSTM이 극단적인 오차를 방지하는 데 더욱 효과적임을 보여준다.

마지막으로 최소 거리에서는 STL-CNN-LSTM이 CNN-LSTM보다 약 32.1% 감소한 1.27m로 나타났다. 이는 STL-CNN-LSTM이 전반적으로 안정적인 예측 성능을 유지하며, 최소 오차에서도 우수한 결과를 보였음을 시사한다.

종합적으로 STL-CNN-LSTM은 CNN-LSTM에 비해 모든 거리 지표에서 일관된 성능 향상을 보여, 모델의 안정성과 정확성을 입증하였다.

## 4. 결 론

본 연구는 합성 LSTM 모델을 이용하여 선박의 항적 예측 분석을 해보았다. 선박의 항적 예측이 정교해진다면 이

는 세밀한 선박 충돌회피 전략 수립에 기여할 수 있고, 이를 기반하여 자율운항선박의 충돌회피 동작을 미세하게 제어할 수 있기 때문이다. 두 가지 모델을 통한 분석 결과 STL-CNN-LSTM이 CNN-LSTM보다 여러 측면에서 높은 예측 정확도를 보여주었다. 대략적을 1~5미터 사이의 오차를 보여주었는데, 이는 모델 선박의 크기를 고려하였을 때 아주 작은 오차라고 할 수 있을 것이다.

본 연구를 기반하여 추후에는 선박의 충돌회피 동작을 어떻게 수립하여 회피할 것인지에 대해 자율운항 선박에 적용한 연구를 진행할 예정이다.

## References


[1] Abebe, M., Y. Noh, Y. J. Kang, C. Seo, D. Kim, and J. Seo (2022), Ship trajectory planning for collision avoidance using hybrid ARIMA-LSTM models. Ocean Engineering, 256, 111527.

[2] Gers, F. A., J. Schmidhuber, and F. Cummins(2000), Learning to forget: Continual prediction with LSTM. Neural computation, 12(10), pp. 2451-2471.

[3] He, R., L. Zhang, and A. W. Z. Chew(2022), Modeling and predicting rainfall time series using seasonal-trend decomposition and machine learning. Knowledge-Based Systems, 251, 109125.

[4] Hajirahimi, Z. and M. Khashei(2019), Hybrid structures in time series modeling and forecasting: A review. Engineering Applications of Artificial Intelligence, 86, pp. 83-106.

[5] Karijadi, I. and S. Y. Chou(2022), A hybrid RF-LSTM based on CEEMDAN for improving the accuracy of building energy consumption prediction. Energy and Buildings, 259, 111908.

[6] Shohan, M. J. A., M. O. Faruque, and S. Y. Foo(2022), Forecasting of electric load using a hybrid LSTM-neural prophet model. Energies, 15(6), 2158.

[7] Li, T., M. Hua, and X. U. Wu(2020), A hybrid CNN-LSTM model for forecasting particulate matter (PM2. 5). Ieee Access, 8, pp. 26933-26940.

[8] Lee, H. J. and D. J. Park(2024), Collision evasive action timing for MASS using CNN-LSTM-based ship trajectory prediction in restricted area. Ocean Engineering, 294, 116766.

[9] Yang, S., Z. Deng, X. Li, C. Zheng, L. Xi, J. Zhuang, and Z. Zhang(2021), A novel hybrid model based on STL decomposition and one-dimensional convolutional neural networks with positional encoding for significant wave height forecast. Renewable Energy, 173, pp. 531-543.

[10] Zha, W., Y. Liu, Y. Wan, R. Luo, D. Li, S. Yang, Y. Xu (2022), Forecasting monthly gas field production based on the CNN-LSTM model. Energy, 124889.

[11] Zhang, L., Y. Zhu, J. Su, W. Lu, J. Li, and Y. Yao(2022), A hybrid prediction model based on knn-lstm for vessel trajectory. Mathematics, 10(23), 4493.

[12] Zhu, H., R. Xu, and H. Deng(2022), A novel STL-based hybrid model for forecasting hog price in China. Computers and Electronics in Agriculture, 198, 107068.



Received : 2025. 01. 31.
Revised : 2025. 03. 06. (1st)
: 2025. 03. 11. (2nd)
Accepted : 2025. 04. 25.